

基于强化学习决策的文档理解与检索多模态问答系统

刘天翔 杨毅涵 郭翊涛

计算机科学与技术

中山大学计算机学院

2026 年 5 月 7 日



目 录

- 1 研究背景与目标
- 2 相关工作调研
- 3 系统架构
- 4 模型与评测
- 5 计划与预期



研究背景

- 在学习和生活中关键信息分布在 PDF、PPT、扫描件等非结构化文档
- 传统的 RAG 主要针对纯文本数据设计，忽略了文档中丰富的视觉结构信息
- 随着多模态大语言模型（MLLM）的快速发展，模型能够直接处理视觉输入的能力，使得多模态 RAG 成为提升文档理解效率的关键技术路径

任务定义与核心目标

- 构建可自主决策的多模态文档智能助手，在生成回答的同时，精准定位并标注引用的页面坐标、图表编号或视频时间戳
- 多模态 RAG 架构构建：建立统一的向量索引池，将文本语义、表格结构描述与图像/视频的视觉特征进行跨模态对
- 通过 GRPO 强化学习训练轻量路由模型，选择合适 VLM 推理

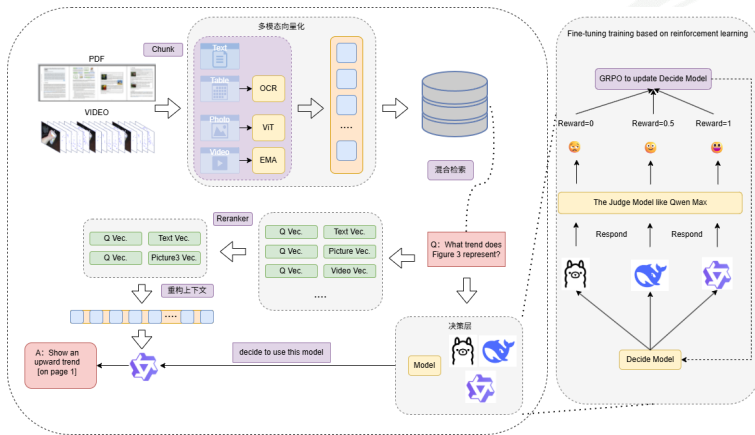
相关工作调研（1）

- *RAG-Anything: All-in-One RAG Framework* [1]
该框架构建了覆盖 PDF 与图像等文件的全模态解析流水线
- *Scaling Beyond Context: A Survey of Multimodal RAG for Document Understanding* [2]
该综述探讨了多模态 RAG 克服传统 OCR 提取局限的技术路径，强调通过视觉模型直接理解图表与排版
- *ColPali: Efficient Document Retrieval with Vision Language Models* [3]
ColPali 摒弃繁琐 OCR 预处理的端到端视觉空间检索架构，而是直接将视觉语言模型直接应用于文档图像嵌入

相关工作调研 (2)

- *DeepSeek-OCR 2: Visual Causal Flow* [4]
DeepSeek-OCR-2 能直接将多页复杂文档转化为包含排版与定位框标记等视觉结构信息的 Markdown 文件
- *Efficient Motion-Aware Video MLLM* [5]
该研究设计了一种能够高效处理动态视频序列的运动感知多模态大模型
- RAGFlow
(<https://github.com/infiniflow/ragflow>)
项目 RAGFlow 是一款为处理复杂排版数据而构建的开源 RAG 框架

系统架构图



模型路由决策模块

- 基于意图分类的前置决策层，选择最优多模态模型路径
- 训练阶段生成多种决策，由评测模型给分
- 使用 GRPO 更新路由权重，使其在不同问题类型上自适应选择

多模态向量化

- 文本：BGE-m3 向量化形成基础索引
- 表格：OCR 转 Markdown，保留结构化特征后向量化
- 图片：ViT 等视觉编码提取特征并保留空间位置信息
- 视频：运动感知 MLLM 融合时序特征，降低冗余 token

在线检索与决策

- 混合检索：同时检索文本库、表格 Markdown 与视觉摘要
- Rerank 重排序：BGE-Reranker-v2-m3 二次打分，过滤噪声

Generation 生成阶段

- 上下文构建：拼接文本、表格与视觉描述，形成结构化输入
- VLM 推理：通过 prompt 约束标注页码、图表来源等溯源信息



模型选择

- Decide 决策模型：Qwen-0.5B + GRPO 强化学习
- 嵌入模型：DeepSeek-OCR-2, BGE-Reranker-v2-m3
- VLM：Qwen2.5-VL, LLaMA 3.2 Vision, DeepSeek-VL

评测数据集与指标

算力预算

- NVIDIA GeForce RTX 5090 32GB $\times$ 1
- NVIDIA GeForce RTX 3070 8GB $\times$ 1

评测数据集与指标

- 数据集：DocVQA、ChartQA 子集（必要时自建数据集）
- 检索与路由：Recall@K、MRR
- 回答质量：ANLS、EM

时间计划与预期成果

时间	任务	具体内容	完成情况
2026.3.5–2026.4.15(6weeks)	确定选题、文献调研	确定小组项目选题，并完成相关论文和项目调研	✓
2026.4.16–2026.5.7(4weeks)	系统设计、开题报告	完成系统架构与开题报告材料撰写	✓
2026.5.7	制作 PPT、上台展示	完成开题报告展示材料与答辩	✓
2026.5.8–2026.6.11(4weeks)	项目开发 with 实现	任务分工并开发核心功能	
2026.6.12–2026.6.17(1week)	项目评测	验证基础功能并完成评测	
2026.6.18–ddl	最终报告的撰写	完成最终项目报告	
ddl	期末验收	准备期末展示材料：PPT、demo 等	

预期成果

- 文档智能助手系统原型，支持检索问答与引用溯源
- 代码实现与技术文档（训练、集成、部署与测试说明）
- 完整项目报告，包含实验结果、可视化与反思展望
- 期末验收：PPT 与 Demo 用于期末验收

参考文献 I

-  Z. Guo, X. Ren, L. Xu, J. Zhang, and C. Huang, “Rag-anything: All-in-one rag framework,” 2025. [Online]. Available: <https://arxiv.org/abs/2510.12323>
-  S. Gao, S. Zhao, X. Jiang, L. Duan, Y. X. Chng, Q.-G. Chen, W. Luo, K. Zhang, J.-W. Bian, and M. Gong, “Scaling beyond context: A survey of multimodal retrieval-augmented generation for document understanding,” *arXiv preprint arXiv:2510.15253*, 2025, arXiv:2510.15253v3, 20 Apr 2026.

参考文献 II

-  M. Faysse, H. Sibille, T. Wu, B. Omrani, G. Viaud, C. Hudelot, and P. Colombo, “Colpali: Efficient document retrieval with vision language models,” *arXiv preprint arXiv:2407.01449*, 2024, arXiv:2407.01449v6, 28 Feb 2025.
-  H. Wei, Y. Sun, and Y. Li, “Deepseek-ocr 2: Visual causal flow,” 2026. [Online]. Available: <https://arxiv.org/abs/2601.20552>
-  Z. Zhao, Y. Huo, T. Yue, L. Guo, H. Lu, B. Wang, W. Chen, and J. Liu, “Efficient motion-aware video mllm,” 2025. [Online]. Available: <https://arxiv.org/abs/2503.13016>

谢谢

感谢老师与同学们的聆听。

